合同哨兵
CONTRACTGUARD

MULTI-AGENT / RAG / CONTRACT REVIEW

把一份采购合同，变成一张可执行的风险清单。

面向中小企业的多 Agent + RAG 合同初审系统

规则 × 三个审查 Agent × 混合检索 | 证据定位、法条校验、人工复核、可交付导出

个人项目 · 全栈 / AI 应用工程 · 2026.11

LangGraph | Hybrid RAG | FastAPI | React 19 | Electron



结果详情：原文证据 / 法条依据 / 复核动作

不是再做一个合同聊天机器人，而是把初审做成一条可验收的流水线

中小企业没有专职法务，采购合同又高度模板化：真正的瓶颈是漏审、不可核对、不可交付。

PROJECT SCOPE

只做一种合同：中文货物采购。

刻意收窄场景，换取三件事：

可核验的法条与 Playbook
32 条法条 + 25 条企业规则

可复现的评测资产
8 份合成合同 + 51 个标注点

可交付的工程闭环
API / Web / 桌面端 / Docker

输出是“AI 辅助初审初稿”，
不构成法律意见。

01

看不全

条款多、模板化，漏掉付款 / 验收 / 违约中的一条，就可能在履约时失控。

→ **25 条确定性规则保召回； 3 个审查 Agent 按主题并行补语义。**

02

说不清

LLM 会编法条、编原文；结论如果不能回到条款原文，就无法用于正式流程。

→ **证据 / 法条门禁：模型只能引用 ID，正文由后端从知识库渲染。**

03

落不了地

结果没有复核、状态与交付物；刷新或重启后任务丢失，报告也只是一段文本。

→ **已核实高风险 HITL；任务快照与 checkpoint； Word / Markdown / JSON 报告。**

一次上传，走完从审查到交付的闭环

风险清单不是终点：每条结论都带证据，已核实高风险必须处理，报告可预览、可导出。

01 上传与解析

PDF / DOCX / TXT / JPG / PNG ； 扫描件走本地 OCR 。

02 并行审查

25 条规则 + 3 个 Agent 在同一超步并行；合并去重。

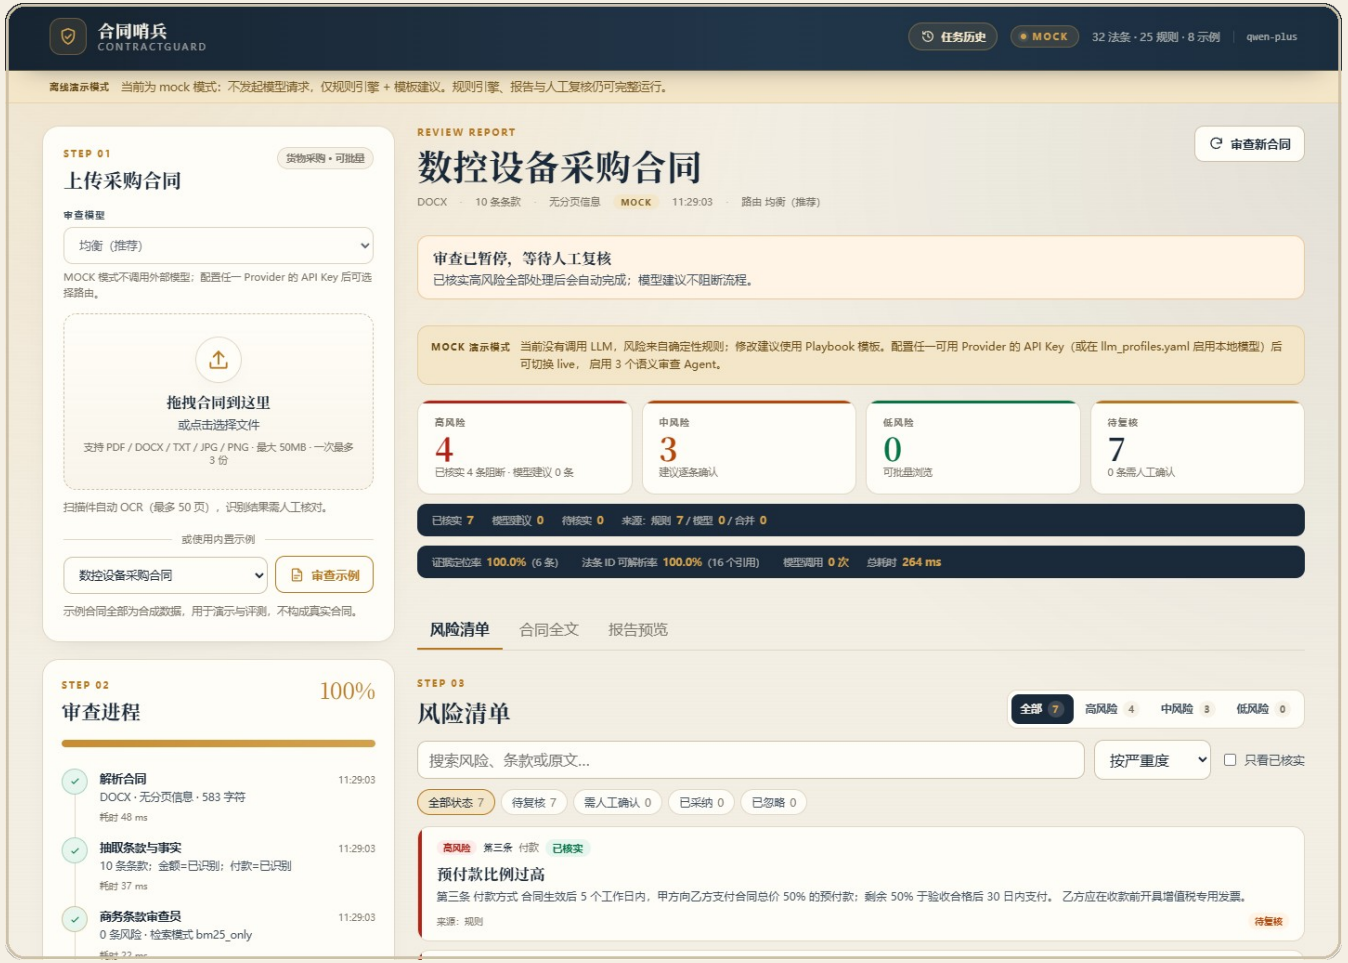
03 逐条复核

原文证据定位；采纳 / 忽略；已核实高风险阻断导出。

04 交付

Word / Markdown / JSON ； 合同修订稿 DOCX ； 批量报告。

截图为 mock 演示模式； live 模式复用同一流程与门禁。



风险清单 / 审查进度 / 导出门禁在同一页面

系统架构 | 把模型放进可恢复的工程流水线

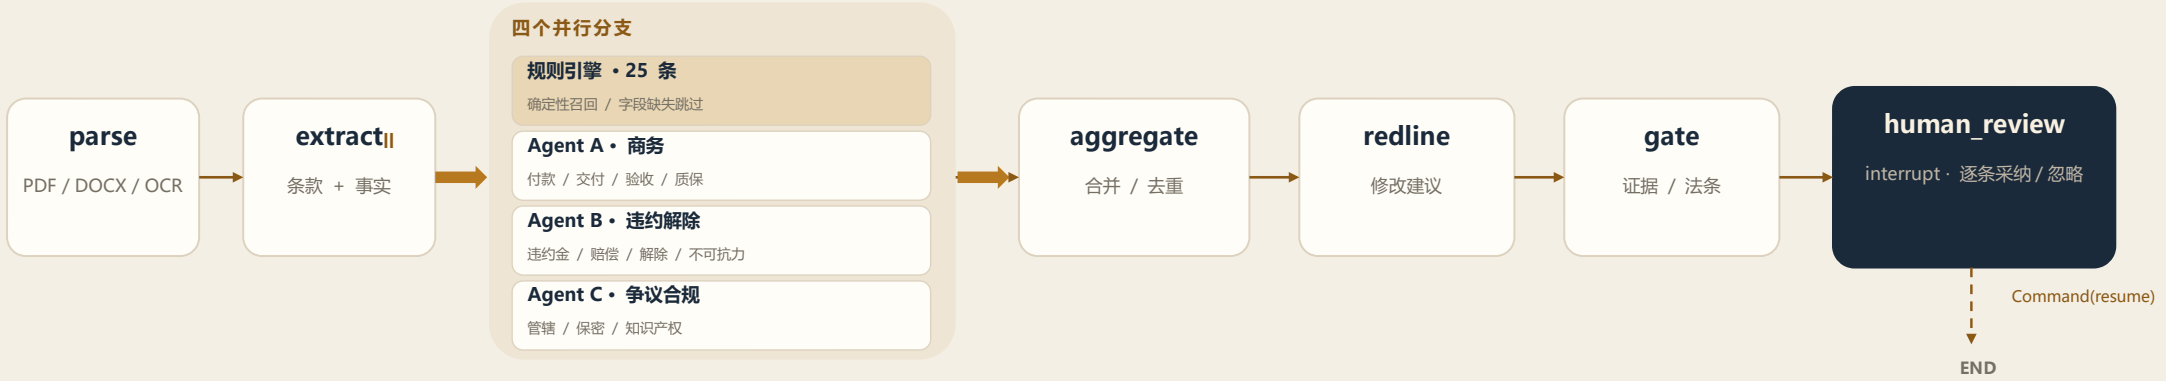
Web / Desktop / Docker 三个入口，共用同一套 API 、任务存储、审查图与交付物。

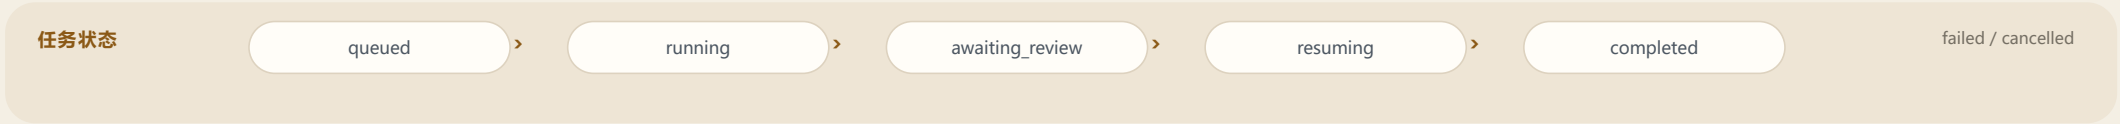


横切： /api/metrics · feedback v2 / run trace · 备份恢复 · Electron 打包 · Docker · 5 条 CI 流水线

核心编排｜四个并行分支，一个可暂停的图

LangGraph 同一超步并行四个分支； HITL 通过 interrupt + checkpoint 暂停与恢复。





01 并发是真的吗?

LangGraph 同一超步里，同步节点不会自动并发。改成 async def + AsyncOpenAI 后， 3 个 Agent 的 HTTP 请求才真正同时发出；同一节点失败只影响该分支，最后由 reducer 收口。

02 暂停存在哪里?

interrupt 不是前端假暂停：图状态写入 AsyncSqliteSaver ，重启后 Command(resume) 继续；running 崩溃不重放 LLM ，避免重复计费。 checkpoint 与任务快照分库，避免写锁。

RAG 与防幻觉 | 每条结论都要回到原文和法条

混合检索不是堆技术： BM25 保关键词，向量补语义， RRF 融合；再用四道门禁约束模型输出。

RETRIEVAL PIPELINE



57 条文档规模 · 精确检索足够，不引入向量数据库

01 Schema 门禁

模型输出必须通过 Pydantic schema； 字段不合法直接失败 / 重试。

02 证据门禁

evidence_quote 必须是合同条款的逐字子串；否则降级为“待核实”。

03 引用门禁

只能引用检索上下文里存在的法条 ID； 正文由后端从知识库渲染。

04 人工门禁

已核实高风险必须逐条采纳 / 忽略；未处理完，报告导出返回 409。

模型不能生成法条原文。它只能返回法条 ID； 正文由后端从知识库渲染。

no-RAG → RAG： 无法条引用 42.9% → 1.3%

可信分层｜模型说的，不等于已核实

置信度来自可验证的流程状态，不来自模型自评分数。

已核实

VERIFIED

规则实际命中，或规则 + 模型合并；高风险必须人工复核。

本次 live 评测：已核实层 P 100%

模型建议

ADVISORY

有原文证据和法条，但没有规则佐证；不阻断导出，但必须显式标注。

本次 live 评测：模型建议层 P 7.1%

待核实

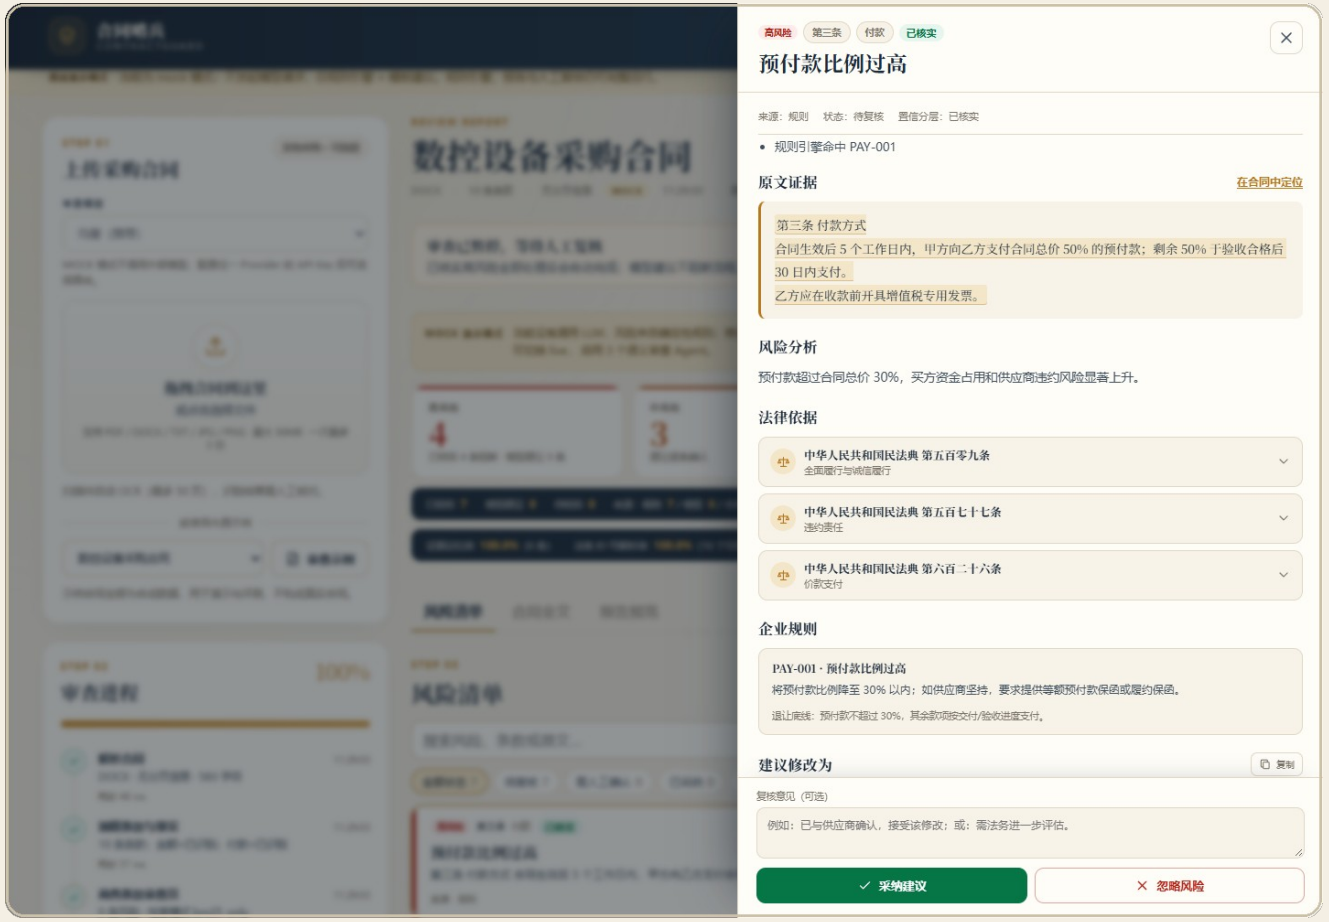
NEEDS REVIEW

证据定位或法条引用不足；要求人工确认，不进入自动结论。

不是“低风险”，而是“缺少可验证依据”

WHY

不用模型自评分，因为模型无法可靠判断自己是否幻觉。只看三个可验证状态：规则是否真的命中、证据能否定位、法条是否在检索集。



界面截图为 mock 模式；原文证据 / 法条 / 企业规则 / 人工复核

交付闭环｜从采纳建议到可交付的修订稿

复核完成后，已采纳建议自动落到新合同文本，生成 DOCX 与逐条变更清单。



修订稿：变更清单 / 修订后全文 / 下载 DOCX

界面截图为 mock 演示模式；live 流程与门禁一致。

REVISED CONTRACT

复核结果变成可交付文本

不是把建议堆在报告里，而是把采纳项落到合同正文。

替换 / 原位标注 / 补充条款

按采纳建议生成；模板建议只标注，不篡改原文。

DOCX + 变更清单

每条变更保留人工意见；修订稿可下载、可对比。

门禁与报告一致

未复核已核实高风险时，修订稿同样不可导出。

BATCH REVIEW

批量审查

最多 3 份 / 批
2 份并发
批次报告 Word / MD / JSON



工程化 | 不只 Demo：可恢复、可审计、可交付

单机部署也能做到任务不丢、状态可恢复、数据边界清晰； CI 把评测与安全变成门禁。

258	离线测试	82.8%	后端覆盖率
	pytest · mock 全链路		CI 门槛 ≥ 80%
5	条 CI 流水线	AES-GCM	静态加密
	后端 / 前端 / E2E / Docker / 桌面		任务快照 · checkpoint · feedback

可靠性

任务不因刷新 / 重启消失

- SQLite JobStore 快照 + 事件
- 租约 Worker： CAS 领取 / 心跳 / reaper
- resuming 最多重试 3 次
- running 崩溃不重放 LLM，避免重复计费

安全与治理

边界写进代码，不只写在文档

- 单租户 Bearer Token + Host 校验
- 上传 / 解析 / 页数 / 解压大小限额
- AES-GCM 可选加密； PII 扫描；删除墓碑
- 反馈、 trace 、评测数据带 provenance

交付与观测

从浏览器到 Windows 安装包

- Docker 单端口 mock 演示
- Electron 自动拉起后端 · 托盘 · 通知
- /api/metrics · run trace · 反馈 v2
- 浏览器 E2E + 桌面打包 smoke

TASK STATE

queued › running › awaiting_review › resuming › completed

failed / cancelled → retry

测试与覆盖率记录： docs/LAUNCH_ACCEPTANCE.md | CI： .github/workflows/ci.yml | 版本： 2026-11-02

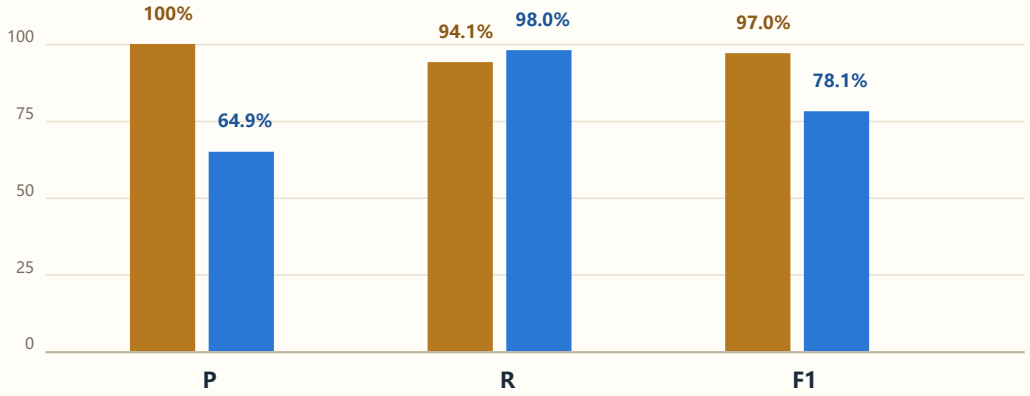
评测｜先证明它可信，再谈它聪明

规则基线可复现； LLM 全量结果按来源与置信分层披露，不用一个总分掩盖误报。

规则基线 vs LLM 全量｜P / R / F1

规则 LLM 全量

8 份合成合同 · 51 个标注点 · live 结果已落盘

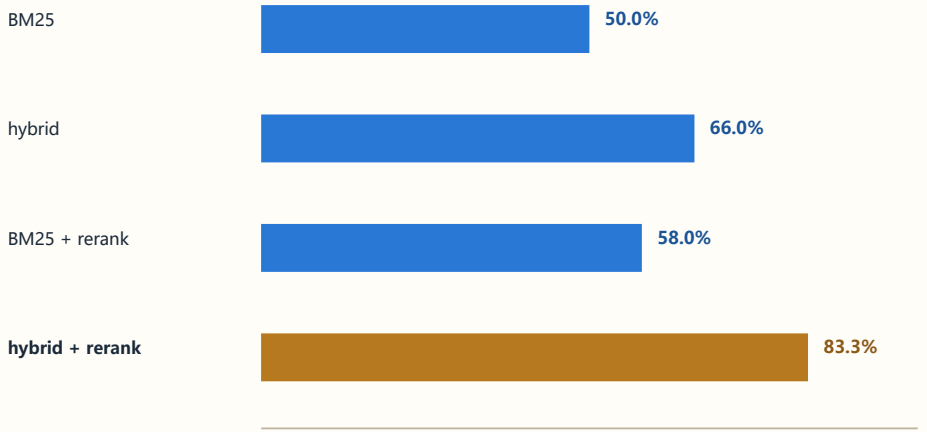


No-RAG 消融： P 59.5% / F1 74.1%； 无法条引用率 42.9% vs full 1.3%

full 的 27 个误报全部来自 LLM，没有纯规则误报。

检索消融｜Recall@10

25 条作者构造 query · 32 条法条语料



Hit@10： 80 → 88 → 84 → 96% ｜ 最佳配置加粗 / 金色

100%	证据定位率	100%	法条 ID 可解析	¥0.0205	估算成本 / 份	92.6s	p95 延迟
	71 条引用		181 个引用		假设单价		8 份 live

口径说明： 8 份合成合同由作者与规则一起构造，规则基线接近满分是“构造使然”，不代表真实泛化； full 的 P 64.9% 与已核实层 P 100% 必须同时看。真实合同目前仅 3 份、单人标注、无 IAA，下一阶段补 20–30 份双人盲标。

来源： backend/eval/results_rules.json · results_full.json · results_retrieval.json · report_cost.md （2026-11-02）

取舍 | 每个决定，都同时写下收益和代价

从 3 天核心 MVP 到可交付版本：明确知道哪些能力先不做。

LangGraph 状态图

并行、可暂停、节点可单测；技术代表性好。

代价 学习曲线； checkpointer 绑定 lifespan 。

规则 + LLM 双轨

规则保确定性 / 召回， LLM 补语义与上下文。

代价 需要去重、冲突处理和统一证据口径。

确定性置信分层

只信可验证状态，不把模型自评分当可信度。

代价 三档不是概率校准，只能表达流程状态。

SQLite 租约 Worker

不引入 Redis / Celery ，单机多进程也能安全领取。

代价 不是高吞吐队列；规模上来要换外部队列。

小语料精确检索

57 条文档， numpy 足够； Windows 依赖更少。

代价 语料扩大后需 FAISS / pgvector 。

HITL 只拦已核实高风险

不让模型误报卡死流程；报告仍披露模型建议。

代价 导出结果可能含未复核的模型建议。

没有一个决定是“免费”的；把代价写出来，才知道下一步该在哪个边界上投入。

先闭环 → 再扩规模 → 保持可替换

复盘｜难的不是调用模型，是让结果可信

三个技术难点，对应三种工程约束；下一步优先补真实数据与生产边界。

01 并行不是“同时调用”

LangGraph 同一超步里，同步节点不会自动并发。改成 async def + AsyncOpenAI 后，3 个 Agent 的 HTTP 请求才真正同时发出； findings 由 reducer 合并。

02 幻觉不能靠 prompt 解决

Schema / 证据 / 引用 / 人工四道门禁；把 27 个误报按来源、等级、 Agent 归因，分层披露而不是从指标里删掉。

03 暂停不是前端状态

interrupt + AsyncSqliteSaver ； 暂停任务跨重启仍可继续； running 崩溃不重放 LLM ，避免重复计费。

“演示能跑只是起点；能被信任、被复核、被交付，才是 AI 应用工程。”

如果面试只能记住一句话：我没有把幻觉藏起来，而是把“哪些结论可以信”做成了产品的一部分。

NEXT / ROADMAP

下一步：从可演示到可生产

1 **真实数据**

20–30 份真实合同 · 双人盲标 · IAA · holdout

2 **生产边界**

多租户 / RBAC / TLS · 对象存储 · 外部队列

3 **审查深度**

版面结构化 OCR · 条款级 diff · 更多合同类型

优先级：数据可信度 > 生产隔离 > 能力扩展

60 秒，看完从合同到可交付的审查流水线

VIDEO / 60s

真实界面录屏：选择示例 → 并行审查 → 证据详情 → 逐条复核 → 修订稿 → 报告预览

01 **选择示例**
合成合同 · mock 模式

02 **并行审查**
规则 + 3 个 Agent

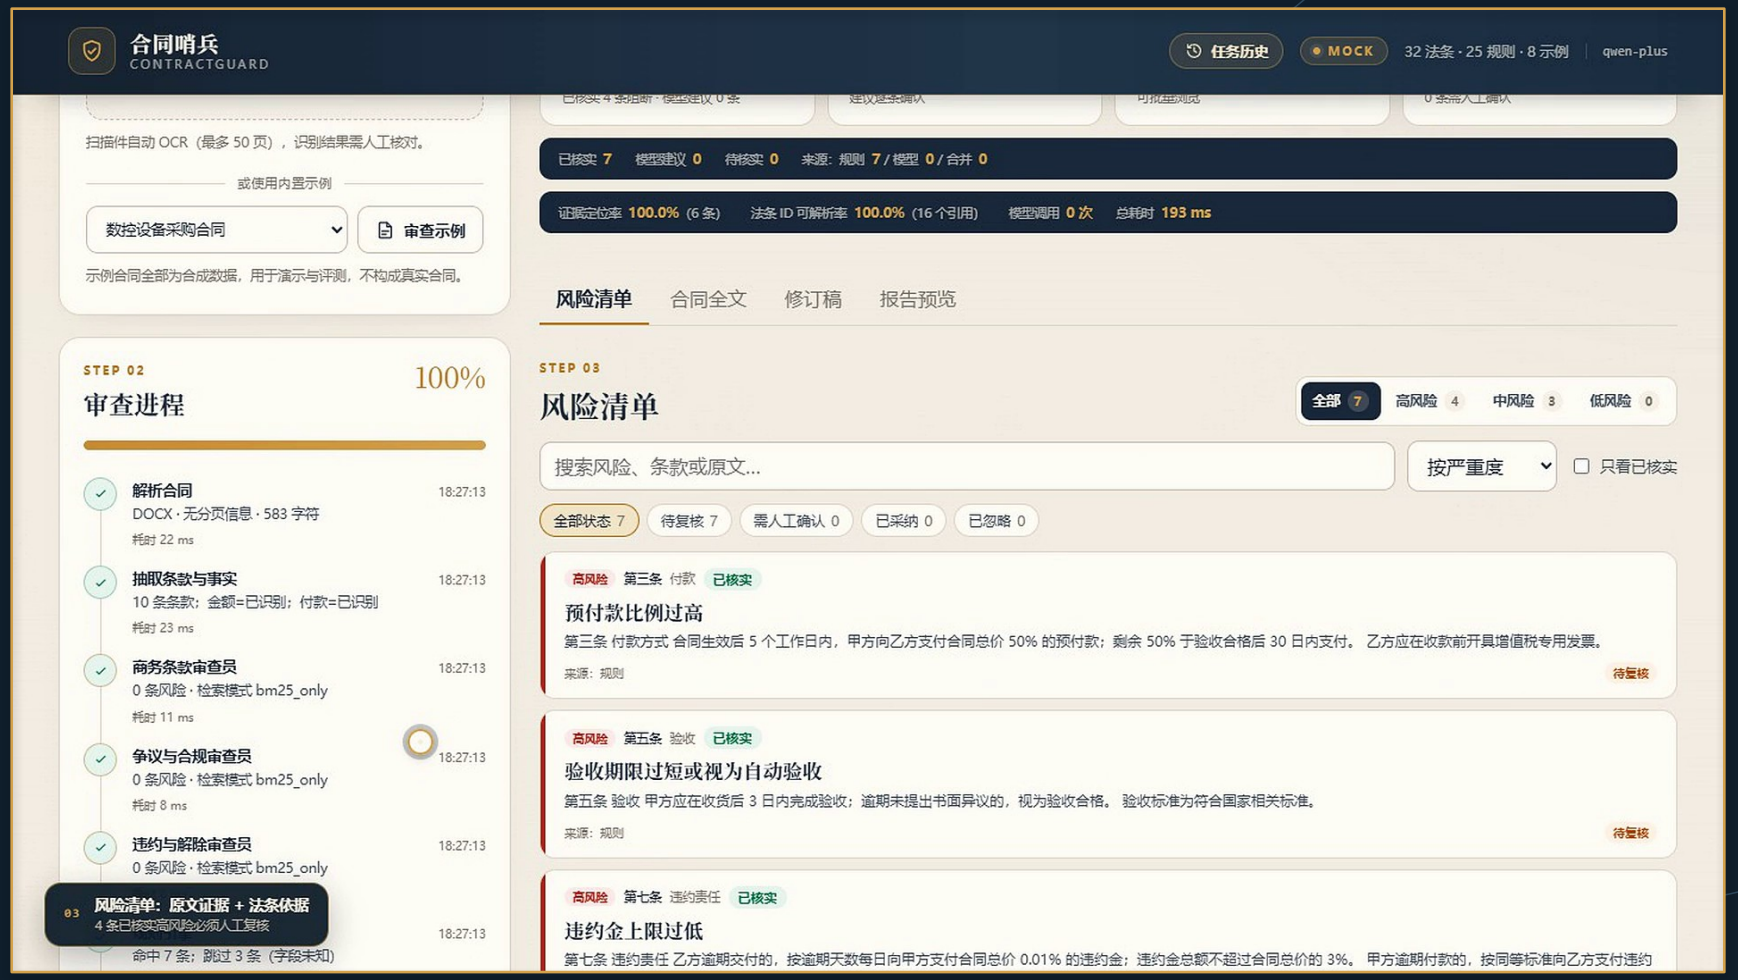
03 **风险清单**
原文证据 + 法条

04 **人工复核**
4 条已核实高风险

05 **交付**
修订稿 + 报告预览

▶ 点击画面播放
60 秒 · 1080p · 男声旁白

视频内嵌于 PPTX； PDF 仅显示封面帧。



DEMO / click to play

THANK YOU / Q&A

让 AI 的结论，回到证据、法条和人。

ContractGuard 把一次合同初审拆成可解释的流水线：
规则保确定性， Agent 补语义，门禁保可核对，人做最后判断。

01 场景窄

只做中文货物采购，才能把规则、法条、评测一起做深。

02 证据链

每条结论回到原文与法条；模型不生成法条原文。

03 工程化

任务可恢复、结果可复核、报告可交付； 258 个离线测试。